



大模型接口

首先明确一个点

对于我们大多数人来说，大模型本身我们无需开发，也没有能力开发。所以我们通常说ai落地，我们都是调用各厂商提供的大模型接口。**你也不用去试图整自己的大模型，也整不出来**



我们需要开发



我们需要开发



直接用厂商现成的

国内大模型接口厂商类型

涵盖多家大模型的集成接口-比如字节家和阿里家的接口

这两家的接口除了自家的模型之外，你还可以选择一些其他家的模型，如deepseek， kimi这些

大模型厂商自己的接口

DeepSeek和kimi都有自己的对外接口。
这些接口一般模型只能选择自家的不同版本模型

用http直接请求

我们可以看到，基本这些大模型的接口都是http接口。所以我们肯定可以直接发起http请求。

但是要注意我们要找到可以http直接请求的接口。他和我们后面用sdk库请求的是不一样的

```
axios.post("接口地址",
{
  //给模型接口的具体消息，作为post请求的请求体
  model: "qwen-plus",
  messages: [
    {
      role: "user",
      content: "你是谁？"
    }
  ]
},
{
  headers: {
    "Authorization": `Bearer ${你的apiKey}`,
    "Content-Type": "application/json"
  }
})
```

详细聊一聊接口的请求体

我们可以看到给到大模型的请求体，他有两个核心属性。

`model`-具体调用的大模型，可以查看接口的文档的模型列表

`message`-具体给大模型的消息

```
{  
  model: "qwen-plus",  
  messages: [  
    {  
      role: "user",  
      content: "你是谁?"  
    }  
  ]  
}
```

示例

```
{
  model: "qwen-plus",
  messages: [
    {
      role: "system",
      content: "你是一个优秀的前端开发工程师，你公司使用的是element+vue3开发..."
    },
    {
      role: "user",
      content: "怎么写一个文件上传"
    },
    {
      role: "assistant",
      content: "文件上传应该先..再.."
    },
    {
      role: "user",
      content: "文件上传怎么切片"
    }
  ]
}
```

role有哪些？

system-系统描述，一般用来携带帮助AI更准确回答的问题的整体情况。

assistant-AI之前的回复,大模型接口没有状态，你每次提问他是不会记得上一次的问题和回答的，所以要带上

user-用户具体的问题，一般用户输入啥就原封不动给过去

```
{  
  role: "user",  
  content: "怎么写一个文件上传"  
}
```

上面这个消息，role我们已经理解了，接下来聊一聊content。

content不只是一个字符串，他也可以是数组，比如下面这段

```
{  
  role: "user",  
  content: [  
    { type: "text", content: "把下面的设计图变成代码" },  
    {  
      type: "image_url", image_url: { url: "xx" }  
    }  
  ]  
}
```

一般常见于给AI图片的时候，上面是文字描述，下面的type为image_url代表是给他一个图片


```
{
  "choices": [
    {
      "message": {
        "role": "assistant",
        "content": "ai的回答"
      },
      "finish_reason": "stop",
      "index": 0,
      "logprobs": null
    }
  ],
  "object": "chat.completion",
  "usage": {
    ...
  },
  "created": 1770118257,
  "system_fingerprint": null,
  "model": "qwen-plus",
  "id": "chatcmp1-957c7553-5ef2-995e-9b4a-9d81c38b4a89"
}
```

核心解析-choices

choices是核心，里面包含具体的回答。使我们核心要用的东西。通常里面只会有一个选项，我们直接取第一个就好。

choice对象里包含

message-本次的具体回答内容(如果是流式传输，没有message，是delta)

finish_reason-完成原因，通常不用管它

index-在choices数组里的序号，通常不关心

logprobs-对数概率，既模型认为该回答和提问的相关度，如果有多个回答，可以做参考。

```
[
  {
    "message": {
      "role": "assistant",
      "content": "ai的回答"
    },
    "finish_reason": "stop",
    "index": 0,
    "logprobs": null
  }
]
```

其他可能有用属性解析

id - 每次调用接口提问，接口的回答都会有一个独特的id。这个id在做流式传输的时候非常有用

usage – 本次问答消耗的token相关

```
{
  "prompt_tokens": 11,
  "completion_tokens": 66,
  "total_tokens": 77,
  "prompt_tokens_details": {
    "cached_tokens": 0
  }
}
```

一些疑问

message里必须带上system以及之前的问答记录吗？

你可以不带，但是我们说过接口是无状态的，但是我们带上前面的对话可以提升回答的准确性

role一定要准确带上吗？

还是准确性的问题，比如你把system里的消息作为user给过去，多半回答也不会有问题，乱用role发消息也不会有大问题。只是准确地role有利于大模型回答的准确,并且也方便人看懂消息

其他厂商的接口入参和出参也是这样的格式吗？

不一定，但是大多数主流厂商都会遵循这样的一个消息格式。所以你可以把它当成标准。所以你可以当成都一样。